구매관리 RAG

RAG Triad 평가 프롬프트 튜닝 보고서

작성일 2026-10-26 | 가상 DB의 답변 가능 질문 30개 | 생성 모델 3개

평가 범위

검색 근거의 관련성, 답변의 근거 충실성, 질문에 대한 답변 관련성을 확인했습니다. P0와 P1은 동일한 질문과 검색 근거를 사용하며 답변 규칙만 다릅니다.

검색 근거 점수는 P0·P1에 공통 적용

검색 근거 관련성(ContextRelevance): 1.000 | 유효 30/30문항

프롬프트 튜닝이 검색 문서 자체를 바꾸지는 않으므로, 같은 질문·근거에 대해 한 번 계산했습니다. 고유 질문 30개 중 DB 정확 조회 22개, 조건 검증 후 벡터 검색 8개입니다. DB 조회를 포함한 검색·답변 흐름의 평가이며, 순수 벡터 검색이나 임베딩 모델만의 성능 평가는 아닙니다.

모델별 실제 평균

생성 모델	충실성 P0	충실성 P1	관련성 P0	관련성 P1
Qwen3 8B	0.844 유효 30/30	0.989 유효 30/30	0.670 유효 30/30	0.750 유효 30/30
Gemma3 4B	0.964 유효 30/30	0.958 유효 30/30	0.623 유효 30/30	0.810 유효 30/30
Llama 3.1 8B	0.923 유효 30/30	0.983 유효 30/30	0.536 유효 30/30	0.787 유효 30/30

수치는 반올림해 소수 셋째 자리까지 표시했습니다. 각 평균은 해당 지표가 유효하게 계산된 문항을 대상으로 합니다. 표의 값은 지표 점수이며, 답변이 맞을 확률이나 신뢰 확률이 아닙니다.

적용 판단과 평가 범위

P1은 민원 응답·대상 표현이 개선됐지만 일부 모델에 통화 추정·출처 형식 회귀가 생겼습니다. 운영 일괄 반영은 보류합니다. 기존 가상 데이터의 재검사이며 독립 최종 성능은 아닙니다. 공통 유효 문항 비교는 3쪽입니다.

무엇을 측정했는가

RAG Triad의 세 축을 Ragas 지표로 구성했습니다.

평가 축 / Ragas 지표	입력과 확인 내용
검색 근거의 관련성 ContextRelevance	질문 + 검색 근거 묶음 질문별 근거를 묶어서 관련 정보를 포함하는지 확인합니다. P0/P1 공통 점수입니다.
답변의 근거 충실성 Faithfulness	질문 + 검색 근거 + 답변 답변을 주장으로 나누고, 각 주장이 근거로 뒷받침되는지 확인합니다.
질문에 대한 답변 관련성 AnswerRelevancy	질문 + 답변 + 채점 LLM + BGE-M3 답변에서 질문을 재구성하고 원 질문과 임베딩 유사도를 계산합니다.

Ragas의 세 지표를 RAG Triad의 개념에 대응시킨 구성입니다. TruLens의 RAG Triad 구현과 동일한 측정값으로 간주하지 않습니다.

정의 참고: https://www.trulens.org/getting_started/core_concepts/rag_triad/
지표 참고: https://docs.ragas.io/en/latest/concepts/metrics/available_metrics/

검색 근거 관련성은 서로 다른 두 채점 프롬프트를 같은 Qwen3 14B에 전달합니다. 두 개의 독립 모델이 채점한 결과는 아닙니다.

비교에서 고정한 조건

질문·검색 근거·출처·생성 모델 버전·양자화·생성 설정·채점 모델과 설정을 고정하고 프롬프트 규칙만 보완했습니다.

P1에서 보완한 네 가지

1. 숫자나 ID만 나열하지 않고, 질문의 대상과 요청 항목을 포함해 짧게 답변합니다.
2. 민원 찾기는 민원 ID와 기록 내용을 함께 제시하고, 요청 사실과 원인 확정·조치 완료를 구분합니다.
3. 납품일·민원일을 원래 의미로 전달하고, 근거에 없는 통화 단위·발생일·인과관계를 추정하지 않습니다.
4. 사실 문장에 근거 번호를 표시하고, 세부 정보 부족을 관련 기록 자체의 부재로 바꾸지 않습니다.

운영 반영 상태

평가용 프롬프트 후보 P1을 비교한 단계입니다. 운영 프롬프트 변경 여부: 변경하지 않음.

동일 문항에서의 변화

P0와 P1 양쪽에서 점수가 유효한 문항만 짝지어 비교했습니다.

P1은 대상·내용 명시, 날짜·단위 추정 금지, 출처 표시 규칙을 추가한 보완안입니다.

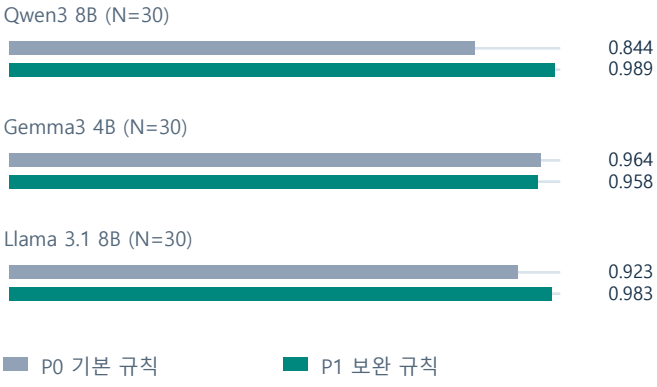
근거 충실성

생성 모델	P0 평균	P1 평균	변화량	공통 N
Qwen3 8B	0.844	0.989	+0.144	30
Gemma3 4B	0.964	0.958	-0.006	30
Llama 3.1 8B	0.923	0.983	+0.060	30

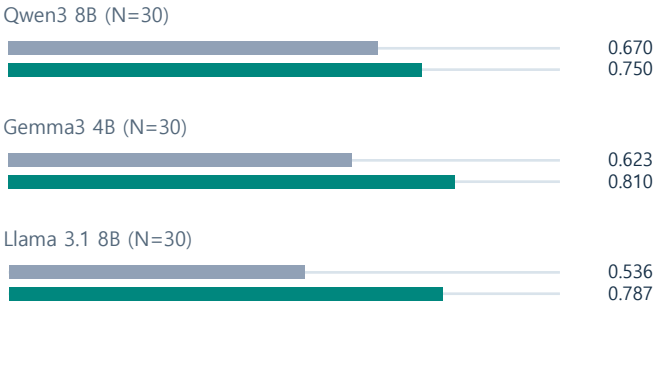
답변 관련성

생성 모델	P0 평균	P1 평균	변화량	공통 N
Qwen3 8B	0.670	0.750	+0.079	30
Gemma3 4B	0.623	0.810	+0.187	30
Llama 3.1 8B	0.536	0.787	+0.250	30

근거 충실성



답변 관련성



P0 기본 규칙 P1 보완 규칙

변화량은 P1 평균에서 P0 평균을 뺀 값입니다. 공통 N=0이거나 계산되지 않은 수치는 N/A로 표시합니다. 정보 없음 응답에서 충실성이 정의되지 않는 경우가 있어, 평균과 함께 실제 답변·유효 수의 변화도 확인해야 합니다.

검색 근거 관련성은 같은 검색 결과의 공유 점수이므로 프롬프트 튜닝 변화량을 만들지 않았습니다.

점수와 함께 보는 실제 답변

답변 원문 발췌를 나란히 배치했습니다. 숫자·날짜·민원 존재 여부도 직접 확인해야 합니다.

Qwen3 8B / Q19 - 관련 민원 존재 여부

실린더 라이너 겉면에 스크래치가 나서 원인과 조치 의견을 요청한 민원을 찾아줘.

P0 기본 규칙	P1 보완 규칙
제공된 문서에서 관련 정보를 찾을 수 없습니다.	민원 ID 3001에서 실린더 라이너 표면에 긁힘이 확인되어 원인 확인과 조치 의견을 요청한 기록이 있습니다 [E1].

Qwen3 8B / Q21 - 날짜 의미 유지

가상 C사의 실린더 라이너 포장에 부품을 식별하는 라벨이 빠졌다는 민원은?

P0 기본 규칙	P1 보완 규칙
가상 C사의 실린더 라이너 포장에 부품을 식별하는 라벨이 빠졌다는 민원은 2026-04-25에 접수된 민원 ID 3003입니다. 해당 민원은 연결 납품 ID 2005의 납품일인 2026-04-23에 발생한 부품 식별 라벨 누락으로 인한 것입니다[E1].	민원 ID 3003에 해당하는 가상 C사의 실린더 라이너 포장에 부품 식별 라벨이 누락되어 식별 정보 확인을 요청한 민원입니다. [E1]

자동 충실성 점수는 1.000입니다. 근거의 납품일은 2026-04-23, 민원일은 2026-04-25이며 문제 발생일은 별도 기록이 없습니다. 채점 모델은 납품일을 발생일로 해석한 주장을 받아들였습니다. 날짜의 역할을 구분하지 못한 자동 채점의 누락 사례이며, 원점수는 수정하지 않았습니다.

Llama 3.1 8B / Q21 - 민원 ID와 출처 표기

가상 C사의 실린더 라이너 포장에 부품을 식별하는 라벨이 빠졌다는 민원은?

P0 기본 규칙	P1 보완 규칙
민원 ID 3003에 해당하는 민원 내용에서, 실린더 라이너 포장에 부품 식별 라벨이 누락되어 식별 정보 확인을 요청한 민원이 있습니다.	가상 C사의 실린더 라이너 포장에 부품을 식별하는 라벨이 빠졌다는 민원은 민원 ID 3003입니다. 부품 식별 라벨이 누락되어 식별 정보 확인을 요청한 민원입니다. [E1]

Gemma3 4B / Q24 - 출처 형식과 날짜 의미의 회귀

베어링을 보호하는 완충재가 부족해서 포장을 보강해 달라는 요청은?

P0 기본 규칙	P1 보완 규칙
베어링 완충 포장이 부족해 포장 보강을 요청하는 민원입니다 [E1].	베어링 완충 포장이 부족하여 포장 보강을 요청한 민원 내용은 2026년 09월 24일(E1) 발생했으며, 가상 C사(E1)의 부품 ID 3인 베어링(가상)에 대한 것입니다.

긴 답변은 앞뒤를 합쳐 180자 이내로 발췌했습니다. 말줄임표는 PDF 표시만 줄인 것이며, 원본 답변 파일과 채점 입력은 바꾸지 않았습니다.

보완안의 부작용도 함께 확인

평균 점수만으로 보완안을 채택하지 않습니다. 아래 검출 수는 Ragas 점수와 별도의 출력 규칙 검사입니다.

생성 모델	통화 단위 추가 P0	통화 단위 추가 P1	출처 표기 오류 P0	출처 표기 오류 P1
Qwen3 8B	0	4	4	0
Gemma3 4B	1	9	0	1
Llama 3.1 8B	0	0	1	0

통화 단위 추가는 통화가 명시되지 않은 등록 단가 질문 9개에서 숫자 뒤의 원 표기를 확인했습니다. 출처 표기 오류는 근거 번호 누락·존재하지 않는 번호를 확인한 수이며, 문장별 출처의 의미적 타당성 검사와는 다릅니다.

새로 늘어난 단위 추정 사례 - Qwen3 8B / Q04

P0 실제 답변	P1 실제 답변
가상 A사에서 공급하는 실린더 라이너의 현재 등록 단가는 10000입니다. [E1]	가상 A사에서 공급하는 실린더 라이너의 현재 등록 단가는 10000원입니다. [E1]

운영 반영 전 확인

보완 규칙을 추가해도 근거 밖 표현이 새로 생길 수 있습니다. 자동 평균이 상승하더라도 이런 회귀 오류를 보완하고 재검증한 뒤 운영 적용 여부를 결정해야 합니다.

원문 대조에서 확인한 추가 회귀

Gemma3 P1의 Q17은 주문 60개와 납품 0개를 제시했지만, 요청한 차이 60개를 직접 명시하지 않았습니다. Q24는 [E1] 대신 (E1)을 사용해 현재 답변 API의 출처 검사에 맞지 않고, 민원일을 발생일처럼 표현했습니다. 자동 점수와 별도로 확인한 AI 보조 원문 검토 결과입니다.

Llama P1은 민원 없음 응답과 출처 누락이 개선됐고, 이번 원문 검토에서는 새 통화·수치·날짜 회귀를 발견하지 못했습니다. 다만 Q20·Q24의 민원 ID 생략 등 일부 형식·완전성 부족이 남아 있습니다. 무오류나 일반 성능을 보장하는 결과는 아닙니다.

재현 조건과 해석 범위

항목	기록된 조건
생성 모델	Qwen3 8B / Gemma3 4B / Llama 3.1 8B
생성 설정	temperature 0 / seed 42 / 입력 8192 / 출력 1024 / CPU 스레드 4 / GPU 레이어 0
공통 채점 모델	qwen3:14b
채점 설정	temperature 0 / seed 42 / 입력 8192 / 출력 4096 / CPU 스레드 4 / GPU 레이어 20
평가 라이브러리	Ragas 0.4.3 / 공식 metrics.collections
관련성 임베딩	BAAI/bge-m3@5617a9f61b028005a4858fdac845db406aefb181

반드시 함께 해석할 한계

• 기존 개발 질문 30개로 조정한 결과입니다. 새로운 질문에 대한 일반 성능이나 독립 최종 검증을 뜻하지 않습니다.
• 생성 답변 평가는 답변 가능한 30문항입니다. 근거 부족·추가 질문 32문항의 백엔드 차단 검사는 생성 모델 점수에 합산하지 않았습니다.
• 공통 채점 모델이 Qwen 계열이므로 같은 계열의 생성 답변에 유리한 편향이 있을 수 있습니다.
• 오류·NaN은 0점으로 바꾸지 않았습니다. 유효 문항 수와 공통 N을 함께 확인해야 합니다.
• 세 지표는 참고 정답 문장을 사용하지 않습니다. 사실 정확성·수치 정확성·출처의 문장별 타당성을 별도로 보장하지 않습니다.
• 짧은 숫자 답변은 값이 맞아도 관련성 점수가 낮을 수 있습니다. P1의 자세한 답변에 근거 밖 주장이 추가됐는지도 확인해야 합니다.
• 관련성은 고정 seed와 동일 요청 캐시로 같은 재구성 질문이 반복될 수 있습니다. 긴 답변이 점수만 높인 경우도 실제 내용으로 확인해야 합니다.
• 통합 총점이나 임의의 합격선을 만들지 않았습니다. 지표와 오류 사례를 함께 판단해야 합니다.

다음 확인

실제 업무 질문을 새로 마련하고, 담당자가 확인한 근거·수치·날짜·출처를 기준으로 재검증합니다. 운영 적용은 이 보고서의 지표와 사례를 확인한 뒤 결정합니다.

수치의 근거 파일

baseline/summary.json · tuned/summary.json · context_relevance/summary.json · paired_comparison.json · tuning_plan.json
실제 답변: Ragas_평가준비의 모델별 Qxx.json 및 tuned_answers의 모델별 Qxx.json
실행 패키지: backend/requirements.txt 및 Ragas_평가준비/requirements-lock.txt