scikit-learn 유사도 필터 성능 재검증 보고서

현재 구매관리 가상 데이터 / 고정 임계값 재검증 / 모델 학습 없음

결론: 기존 시험의 통과·거절 건수를 공식 지표 함수로 재현했습니다. 검증용 30문항 중 23문항을 올바르게 분류했습니다. 정답 없는 질문 3개는 잘못 통과했고, 정답 있는 질문 4개는 잘못 거절했습니다.

조건	설정
임베딩 및 검색	BGE-M3 + Chroma, 문서 47개, top_k=3, 메타데이터 필터 없음
임계값	0.619865 이상이면 통과 문서로 채택
평가 데이터	정답 있음 30개 + 없음 30개. 기존 분할 그대로 유지.
주요 결과 기준	임계값 선정에 사용하지 않은 holdout 30개 (양성15 / 음성15)
도구	scikit-learn 1.9.1 / 실제 API 60회 재요청

혼동행렬: 검증용 30문항

실제 질문 상태	필터가 거절	필터가 통과
정답 근거 없음 (15개)	12개: 올바른 거절 (TN)	3개: 잘못 통과 (FP)
정답 근거 있음 (15개)	4개: 잘못 거절 (FN)	11개: 올바른 통과 (TP)

지표	결과	초보자용 설명
정확도	76.67%	통과·거절 판단이 맞은 비율: 23/30
정밀도	78.57%	통과한 질문 중 실제 정답 근거가 있는 비율: 11/14
재현율	73.33%	정답 있는 질문 중 통과시킨 비율: 11/15
F1	75.86%	정밀도와 재현율의 조화평균
정답 없음 거절률	80.00%	정답 없는 질문을 거절한 비율: 12/15

양성(1)은 정답 근거가 있는 질문입니다. 예측 양성(1)은 필터를 통과한 문서가 하나 이상인 경우입니다. 이 수치는 LLM 답변 정확도나 환각 방지율이 아닙니다.

기존 결과 비교와 실패 사례

구분	정상 통과 TP	잘못 거절 FN	정상 거절 TN	잘못 통과 FP	정확도
기준 선정용 30개	11	4	14	1	83.33%
검증용 30개	11	4	12	3	76.67%
전체 60개	22	8	26	4	80.00%

기준 선정용·검증용 각각의 기존 통과/거절 건수와 모두 일치했습니다. 이전 balanced_success는 정답 문서가 실제로 남았는지도 보던 값입니다. 이번 balanced_accuracy는 질문 통과/거절만 계산합니다. 이번 자료에서는 통과한 양성 질문이 모두 정답 문서를 포함해 두 값이 일치하지만, 일반적으로 같은 지표는 아닙니다.

검증용 질문에서 발생한 오류 7개

ID / 오류	질문	최고 후보 유사도
Q02 / 잘못 거절	가상 B사의 저장된 Q 점수는 얼마야?	0.556033
Q14 / 잘못 거절	1102번 발주에서 주문 수량과 지금까지 납품된 수량의 차이는 얼마야?	0.606977
Q16 / 잘못 거절	1104번 발주에서 주문 수량과 지금까지 납품된 수량의 차이는 얼마야?	0.615689
Q18 / 잘못 거절	1106번 발주에서 주문 수량과 지금까지 납품된 수량의 차이는 얼마야?	0.614877
N16 / 잘못 통과	연료 분사 밸브의 제조사 보증 기간은?	0.646616
N24 / 잘못 통과	가상 E사의 베어링 등록 단가를 알려줘.	0.722087
N26 / 잘못 통과	2025년 12월 가상 B사의 베어링 납품 수량은?	0.633115

해석

보증 기간, 없는 협력사, 다른 연도처럼 질문 주제는 비슷하지만 실제 답이 없는 경우에도 높은 유사도가 나올 수 있습니다. 반대로 실제 답이 있어도 점수가 낮으면 거절됩니다. 따라서 점수만으로 근거의 충분성을 확정할 수 없습니다.

전체 60개 정확도 80.00%는 기준 선정에 사용한 질문을 포함한 참고값입니다. 검증용 30개 결과와 구분해야 합니다. 임계값을 이번 결과에 맞춰 다시 조정하지 않았습니다.

방법·재현 자료·판단 범위

이번에 실행한 절차

1. 기존 질문 60개, 정답 유무, 기준 선정/검증 분할, 임계값 0.619865를 그대로 읽었습니다.

2. 실행 중인 /search API에 같은 질문을 다시 보내 실제 통과 문서와 근거 부족 응답을 확인했습니다.

3. 저장된 필터 적용 전 후보 점수에 같은 기준을 적용한 결과와 실제 API 결과가 모두 일치하는지 확인했습니다.

4. sklearn.metrics의 confusion_matrix, accuracy_score, balanced_accuracy_score, precision_score, recall_score, f1_score로 계산했습니다.

5. 정답 있는 질문이 통과했더라도 엉뚱한 문서만 반환한 경우가 있는지 정답 문서 ID와 별도로 대조했습니다. 이번 자료에서는 0건입니다.

6. 원본 DB·이전 결과·벡터 인덱스 설정·임계값 파일의 해시가 실행 전후 동일함을 확인했습니다.

무엇을 검증하지 않았는가

- 소규모 합성 질문 평가. 기존 정답 질문은 모델 선택에도 사용되었으므로 완전한 신규 벤치마크가 아님.
- 독립 문서 단위 분할이 아닌 질문 단위 분할. 실제 업무 질문으로 추가 검증 필요.
- 유사도는 답변 가능성이나 사실 정확성을 보장하지 않음. 없는 속성/ID도 비슷한 문서를 찾을 수 있음.
- 전체60 결과에는 기준 선정용30문항이 포함되므로 독립 성능으로 해석하지 않음.
- 기준 선정에 사용하지 않은 holdout30문항도 가상 데이터 기반이며 기존 정답 질문은 모델 선택에 이미 사용됨.
- 라이브러리 교체에 따른 재현성 확인이며 새 업무 평가셋 검증이 아님.

이번 작업은 BGE-M3 필터의 이진 분류 평가입니다. 임베딩 모델 3개의 검색 순위 평가는 앞선 InformationRetrievalEvaluator 결과와 별개입니다. 답변 생성 모델이나 별도 AI 채점 모델은 사용하지 않았습니다.

재현 자료

실행 코드: outputs/sklearn_유사도필터평가.py
상세 결과: outputs/sklearn_평가결과/sklearn_유사도필터_검증결과.json
상세 JSON에는 60문항의 기존 후보·점수·실제 반환 ID·오류 분류와 입력 파일 해시가 포함되어 있습니다.

공식 참고 문서

혼동행렬 - scikit-learn 공식 문서

정밀도·재현율·F1 - scikit-learn 공식 문서

운영 판단: 현재 기준은 가상 데이터용 잠정 설정입니다. 사용자 검토를 마친 정답표와 새로운 실제 업무 질문으로 재검증한 뒤 운영 기준을 확정해야 합니다.