공식 InformationRetrievalEvaluator로 재검증

동일 문서 47개 · 동일 질문 30개 · 동일 모델 revision · CPU/배치8 · 유사도 필터 미적용

공식 모듈이 새로 임베딩하고 검색 지표를 계산했습니다. 모델 학습이나 운영 Chroma 재구축은 하지 않았습니다.

모델	Hit@1 (기존 → 공식)	Hit@3	Hit@5	MRR@10	정답 순위 변화
e5-base	76.67% → 76.67%	90.00% → 90.00%	96.67% → 96.67%	0.8500 → 0.8500	0문항
ko-sroberta	70.00% → 70.00%	90.00% → 90.00%	93.33% → 93.33%	0.8117 → 0.8117	0문항
bge-m3	80.00% → 80.00%	93.33% → 93.33%	93.33% → 93.33%	0.8556 → 0.8556	0문항

공식 모듈의 accuracy@k는 이 실험에서 기존 Hit@k와 같은 정의입니다. 기존 점수는 소수 넷째 자리까지 저장했으므로 미세한 수치 차이는 반올림 때문인지 확인해야 합니다.

이번에 바뀐 것과 바뀌지 않은 것

직접 작성했던 Hit/MRR 계산을 공식 평가 모듈로 교체했습니다. 질문과 정답표는 이전 그대로이므로 이 결과는 계산 재현성 확인입니다. 질문의 업무 대표성이나 정답표의 품질을 새롭게 검증한 것은 아닙니다. 새로운 최종 시험이나 공식 인증으로 해석하지 마세요.

다른 도구를 별도로 추가하지 않은 이유

• MTEB: 표준 데이터셋/여러 평가 과제를 확장할 때 유용하지만, 동일한 우리 데이터 검색 평가를 재현하는 이번 작업에는 공식 IR 평가기로 충분합니다.

• NumPy: 필요 없는 라이브러리가 아닙니다. 공식 모듈 내부에서도 사용합니다. 다만 직접 NumPy로 순위와 지표를 구현할 필요가 없어졌습니다.

• pandas: 결과표 정리 도구입니다. 점수 계산에 필수적이지 않아 JSON/HTML로 정리했습니다.

• ir_measures: 실제 Chroma 결과를 채점할 때 유용합니다. 이번 작업은 모델 자체의 전체 문서 검색 비교여서 별도 추가하지 않았습니다.

• scikit-learn: 거절 필터 검증에서 별도로 활용할 수 있습니다. 이번 실험은 정답 있는 질문의 검색 성능만 재현합니다.

• Ragas: 생성 답변의 근거 일치 등을 평가할 때 검토합니다. 이번에는 답변 생성이 없습니다.

E5 query:/passage: 접두어와 SRoBERTa 최대 길이512도 이전과 동일합니다. 토큰 잘림이 없음을 확인했습니다. 시간은 기존 시험과 측정 구간이 달라 속도 우열의 직접 비교에 사용하지 않습니다.

e5-base 공식 원본 지표와 차이

{ "model": "intfloat/multilingual-e5-base", "alias": "e5-base", "revision": "d128750597153bb5987e10b1c3493a34e5a4502a", " max_input_tokens": 270, "used_max_tokens": 512, "official_metrics": { "e5-base_cosine_accuracy@1": 0.7666666666666667, " e5-base_cosine_accuracy@3": 0.9, "e5-base_cosine_accuracy@5": 0.9666666666666667, "e5-base_cosine_precision@1": 0.7666666666666667, "e5-base_cosine_precision@3": 0.3, "e5-base_cosine_precision@5": 0.19333333333333338, " e5-base_cosine_recall@1": 0.7666666666666667, "e5-base_cosine_recall@3": 0.9, "e5-base_cosine_recall@5": 0.9666666666666667, " e5-base_cosine_ndcg@10": 0.879502404347754, "e5-base_cosine_mrr@10": 0.85, "e5-base_cosine_map@47": 0.853030303030303 }, " comparable_metrics": { "hit_at_1": 0.7666666666666667, "hit_at_3": 0.9, "hit_at_5": 0.9666666666666667, "mrr_at_10": 0.85 }, " previous_metrics": { "questions": 30, "hit_at_1": 0.7667, "hit_at_3": 0.9, "hit_at_5": 0.9667, "mrr_at_10": 0.85 }, " delta_against_rounded_previous": { "hit_at_1": -3.33333e-05, "hit_at_3": 0.0, "hit_at_5": -3.33333e-05, "mrr_at_10": 0.0 }, " same_at_previous_4_decimal_precision": true, "gold_rank_changes": [], "top5_order_changes": [], "evaluation_seconds_excluding_load": 8.193 }

ko-sroberta 공식 원본 지표와 차이

{ "model": "jhgan/ko-sroberta-multitask", "alias": "ko-sroberta", "revision": "8fca7c9c98c26599be0e14b9916b11a756a26f19", "
max_input_tokens": 253, "used_max_tokens": 512, "official_metrics": { "ko-sroberta_cosine_accuracy@1": 0.7, "
ko-sroberta_cosine_accuracy@3": 0.9, "ko-sroberta_cosine_accuracy@5": 0.9333333333333333, "ko-sroberta_cosine_precision@1": 0.7, "
ko-sroberta_cosine_precision@3": 0.3, "ko-sroberta_cosine_precision@5": 0.1866666666666667, "ko-sroberta_cosine_recall@1": 0.7, "
ko-sroberta_cosine_recall@3": 0.9, "ko-sroberta_cosine_recall@5": 0.9333333333333333, "ko-sroberta_cosine_ndcg@10":
0.8578041178683248, "ko-sroberta_cosine_mrr@10": 0.8117063492063493, "ko-sroberta_cosine_map@47": 0.8117063492063491 }, "
comparable_metrics": { "hit_at_1": 0.7, "hit_at_3": 0.9, "hit_at_5": 0.9333333333333333, "mrr_at_10": 0.8117063492063493 }, "
previous_metrics": { "questions": 30, "hit_at_1": 0.7, "hit_at_3": 0.9, "hit_at_5": 0.9333, "mrr_at_10": 0.8117 }, "
delta_against_rounded_previous": { "hit_at_1": 0.0, "hit_at_3": 0.0, "hit_at_5": 3.33333e-05, "mrr_at_10": 6.3492e-06 }, "
same_at_previous_4_decimal_precision": true, "gold_rank_changes": [], "top5_order_changes": [], "evaluation_seconds_excluding_load":
7.324 }

bge-m3 공식 원본 지표와 차이

{ "model": "BAAI/bge-m3", "alias": "bge-m3", "revision": "5617a9f61b028005a4858fdac845db406aefb181", "max_input_tokens": 268, "
used_max_tokens": 8192, "official_metrics": { "bge-m3_cosine_accuracy@1": 0.8, "bge-m3_cosine_accuracy@3": 0.9333333333333333, "
bge-m3_cosine_accuracy@5": 0.9333333333333333, "bge-m3_cosine_precision@1": 0.8, "bge-m3_cosine_precision@3":
0.3111111111111111, "bge-m3_cosine_precision@5": 0.1866666666666667, "bge-m3_cosine_recall@1": 0.8, "bge-m3_cosine_recall@3":
0.9333333333333333, "bge-m3_cosine_recall@5": 0.9333333333333333, "bge-m3_cosine_ndcg@10": 0.8753953169047638, "
bge-m3_cosine_mrr@10": 0.8555555555555555, "bge-m3_cosine_map@47": 0.85906432748538 }, "comparable_metrics": { "hit_at_1": 0.8, "
hit_at_3": 0.9333333333333333, "hit_at_5": 0.9333333333333333, "mrr_at_10": 0.8555555555555555 }, "previous_metrics": { "questions":
30, "hit_at_1": 0.8, "hit_at_3": 0.9333, "hit_at_5": 0.9333, "mrr_at_10": 0.8556 }, "delta_against_rounded_previous": { "hit_at_1": 0.0, "
hit_at_3": 3.33333e-05, "hit_at_5": 3.33333e-05, "mrr_at_10": -4.44444e-05 }, "same_at_previous_4_decimal_precision": true, "
gold_rank_changes": [], "top5_order_changes": [], "evaluation_seconds_excluding_load": 27.344 }

Sentence Transformers 공식 평가 문서